ÖRÜNTÜ TANIMA

# Olasılık, Dağılımlar ve Kayıp Fonksiyonları

Hafta 3

Emir Öztürk · Oğuz Kırat

Prior & Posterior | Likelihood | MLE

Dağılımlar | MSE / MAE | Cross Entropy

# Prior ve Posterior Olasılık

## İki temel kavram

### 📌 Prior (Önsel) Olasılık — P(w)

**Veriler gözlemlenmeden önceki bilgi değeri.**
Sistemin ilk olasılıklarını temsil eder. İlk ağırlık değerleri bu dağılıma göre atanır.
**Örnek:** Model ağırlıklarının Gaussian dağılıma sahip olduğu kabul edilebilir.

### 📌 Posterior (Sonrasal) Olasılık — P(w|D)

**Verilerin gözlemlenmesinden sonraki olasılık.**
Prior olasılığa ve gözlenen veriye bağlıdır. **Bayes teoremi:** $P(w|D) \propto P(D|w) \cdot P(w)$
Verilerin ne kadar olası olduğuna bağlıdır (likelihood × prior).

*Prior → veri gözlemlenir → Likelihood hesaplanır → Posterior güncellenir*

- Prior (Önsel) Olasılık
  - Veriler gözlemlenmeden önceki bilgi değeri
  - Sistemin ilk olasılıkları
  - Rastgele ağırlık seçimi
  - $P(w)$
- Posterior (Sonrasal) Olasılık
  - Verilerin gözlemlendikten sonraki olasılık
  - Prior olasılığa bağlıdır.
  - Verilerin ne kadar olası olduğuna bağlıdır (likelihood)
  - $P(w|D)$

# Prior ve Posterior Olasılık — Örnek

## 🏠 Senaryo: Ev Fiyatı Tahmin Modeli

### 1 Prior Belirleme

Evin boyutu ile fiyat arasında normal bir dağılım olduğu varsayılır. Bu başlangıç inancıdır — henüz hiç veri görmeden yapılan kabuller.

### 2 İlk Ağırlıklar

Prior'a dayanarak modelin ilk ağırlık değerleri atanır. Ağırlıklar Gaussian dağılımından örneklenir: $w \sim N(0, \sigma^2)$.

### 3 Veriyi Gözlemle

Gerçek ev satış verileri toplanır: $m^2$ ve fiyat çiftleri. Model bu verilerle karşılaştırılır; likelihood $P(D|w)$ hesaplanır.

### 4 Posterior (Son Durum)

Ayarlanan son model parametreleri posterior olarak kabul edilir. Artık sadece prior'a değil, gözlenen veriye de dayanan parametrelerdir.

**Diğer örnekler →** *Spam filtresi: prior=%20 spam → e-posta gelince posterior=%92 | Tıbbi tanı: hastalık sıklığı %1 → test pozitifse posterior güncellenir*

# Likelihood (Olabilirlik) — Tanım

**Gözlem verisine bağlı olarak mevcut parametrelerin olasılığını ifade eder.**

### Tanım

Verilen parametre w altında D gözlemleme olasılığı:

$L(w) = P(D|w)$

### Önemli Fark

Likelihood bir olasılık değil, bir skordur.
$P(D|w)$: veri sabitken w değişir → bu likelihood
$P(D)$: parametreler sabitken → bu olasılık

### Neden Önemli?

Prior $P(w)$ ile çarpıldığında posterior elde edilir:

$P(w|D) \propto L(w) \times P(w)$

Makine öğrenmesinde loss fonksiyonlarının temeli burasıdır.

### Örnek: Madeni Para

10 atışta 7 tura.
$\theta=0.3 \rightarrow L=0.009$ (düşük)
$\theta=0.5 \rightarrow L=0.117$ (orta)
$\theta=0.7 \rightarrow L=0.267$ (en yüksek)
→ $\theta=0.7$ bu veriyi en iyi açıklar.

### Sıcaklık Sensörü

5 ölçüm: [20.1, 19.8, 20.3, 20.0, 19.9]
Gerçek sıcaklık 20°C parametresi bu veriyi 22°C parametresinden çok daha iyi açıklar.

# Maximum Likelihood (MLE)

*Maximum Likelihood yada MLE (Estimation) verilere en iyi uyan parametrenin bulunması işlemidir.*

### 1 Amacı

Likelihood fonksiyonunu maksimize eden θ değerini bul:
$w = \text{argmax}_w L(w)$
Yalnızca $-\log P(D|w)$ kısmı alınır.

### 2 Nasıl Çalışır?

Model D verisi için w ağırlıklarını kullanır.
Daha sonra $-\log P(D|w)$ hesaplanır (loss).
Backpropagation ile kaybın gradyanı hesaplanır.

### 3 Güncelleme

Bulunan gradyan fark, ağırlıklara yansıtılır.
$w \leftarrow w - \eta \cdot \nabla w \text{ loss}$
Bu adım iteratif olarak tekrarlanır.

### 4 Sonuç

En çok likelihood değeri veren parametreler bulunmuş olur.
MLE nokta tahmini verir; belirsizliği modellemez.

# MLE — Gerçek Dünya Örnekleri

*"Elimdeki veriyi en iyi açıklayan parametreleri bul" — makine öğrenmesinin temel motorudur.*

### 📧 Spam Filtresi

**Veri:** %20 spam (geçmiş veri)
**MLE ne yapar:** "ücretsiz", "acil kazan" gibi kelimeler görülünce likelihood yükselir. MLE bu özelliklerin ağırlıklarını öğrenir.

### 📦 E-Ticaret Öneri

**Veri:** Kullanıcı-ürün etkileşim geçmişi
**MLE ne yapar:** MLE, P(satın alma | kullanıcı, ürün) olasılığını maksimize eden ağırlıkları bulur. Öneri sistemi bu parametrelerle çalışır.

### 🔤 Dil Modeli (GPT)

**Veri:** Milyarlarca cümle
**MLE ne yapar:** P(kelime | önceki kelimeler) olasılığını maksimize eden ağırlıklar öğrenilir. Her token tahmini bir MLE adımıdır.

### 🩺 Tıbbi Görüntü

**Veri:** Etiketli röntgen veritabanı
**MLE ne yapar:** Model P(hastalık=1 | piksel değerleri) olasılığını maksimize eder. Loss = Negatif Log-Likelihood.

💡 *MLE tek bir değer döndürür (nokta tahmini). Belirsizliği modellemek için Bayesian yaklaşım tercih edilir.*

# Dağılımlar

**Farklı veriler için farklı dağılımlar bulunmaktadır.**

### Neden dağılım seçmek önemlidir?

Verinin dağılımını belirlemek parametre tahmininde kullanılmaktadır. Model veriyi üretecek dağılımı öğrenir; bu dağılım yanlış seçilirse model gerçeği yanlış temsil eder.

### Yanlış dağılım seçimi ne yapar?

Eğitim başarılı olmakla beraber yeni veride hata oranı artacaktır.
Yanlış dağılım seçimi sebebi ile ağırlığa sahip olmayan verilere ağırlık verildiği için önyargı (bias) oluşacaktır.
Böyle bir durumda overfitting ve underfitting problemleri ortaya çıkar.

### Kayıp fonksiyonuna etkisi

Modelin dağılımının seçilmesi makine öğrenmesinde kayıp hesaplama kısmına etki etmektedir.
Normal dağılım → MSE loss
Bernoulli/kategorik dağılım → Cross Entropy loss
Poisson dağılımı → Poisson loss

# Dağılımlar — Türler

## Sürekli Veri

| | |
|---|---|
| **Normal** | İnsan boyu, ağırlığı, sınav notları — merkeze yakın değerler yoğun |
| **Üstel** | Müşteri bekleme süresi, makine arızaları arası süre |
| **Gamma** | Sigorta hasar tutarı, deprem bekleme süresi — pozitif, sağa çarpık |

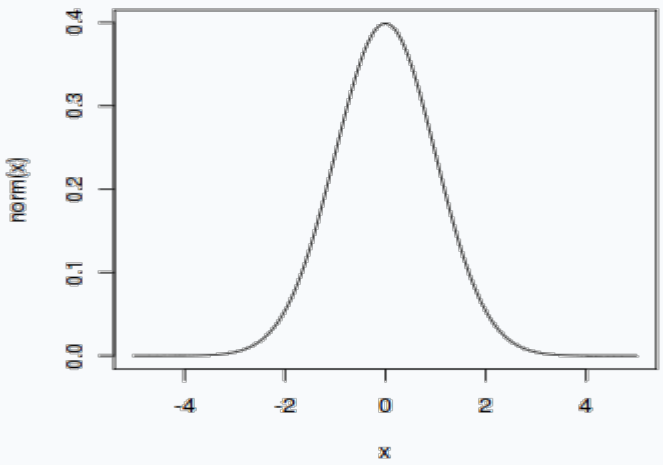


## Ayrık Veri

| | |
|---|---|
| **Binom** | 100 e-postadan kaçı spam? — n deneme, p sabit, başarı/başarısızlık |
| **Poisson** | Saatte gelen müşteri sayısı, web isteği/dk — nadir olaylar |
| **Neg. Binom** | k. satışa kadar kaç görüşme yapılır? — k başarıya ulaşma |
| **Bernoulli** | Tek deneme: tıklama var mı yok mu? — 0/1 sonuç |

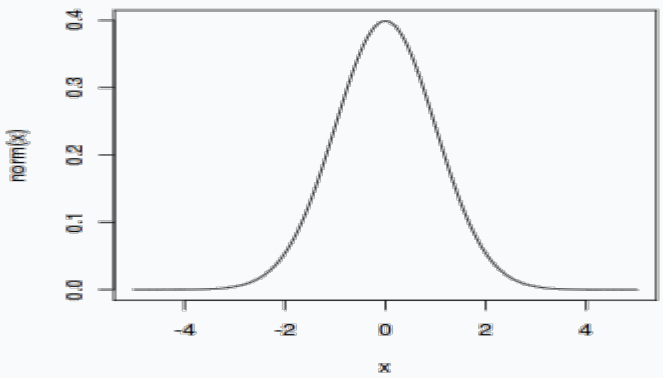

# Dağılımlar — Hangi Veri, Hangi Dağılım?

*Yanlış dağılım seçimi → model gerçek veriyi temsil edemez → bias ve overfitting.*

| Dağılım | Tür | Gerçek Dünya Örneği | Ne Zaman Kullan? |
|---|---|---|---|
| **Normal** | Sürekli | İnsan boyu, ağırlığı, ölçüm hataları, sınav notları | *Merkeze yakın değerler yoğun, uçlar seyrek* |
| **Üstel** | Sürekli | Sipariş arası süre, makine arıza aralığı | *Bekleme süreleri ve ilk-olay problemleri* |
| **Binom** | Ayrık | 100 e-postadan kaçı spam? 1000 kullanıcıdan kaçı tıklar? | *n deneme, her biri başarı/başarısızlık, p sabit* |
| **Poisson** | Ayrık | Bir saatte gelen müşteri sayısı, web isteği/dk | *Sabit süre içinde nadir olayların sayısı* |
| **Neg. Binom** | Ayrık | k. satış öncesi kaç görüşme yapılır? | *k başarıya ulaşmak için gereken deneme sayısı* |
| **Gamma** | Sürekli | Sigorta hasar tutarı, deprem bekleme süresi | *Üstelin genellemesi; pozitif değerler, sağa çarpık* |

# Dağılımlar — Normal Dağılım

### Ortalamaya Yakınlık

Normal dağılımda beklenen verinin elemanlarının çoğunun ortalamaya (μ) yakın olması beklenir. Değerler ortalamadan uzaklaştıkça seyrekleşir.

### Tam Simetri Gerekmez

Bire bir simetri beklenmez. Gerçek dünya verileri çoğunlukla hafifçe çarpıktır; ancak normal dağılım iyi bir başlangıç yaklaşımıdır.

### Varyans ile Şiddet

Şiddeti (yayılımı) farklı olabilir. Düşük varyans → değerler ortalamaya sıkışır. Yüksek varyans → değerler geniş aralığa yayılır.

### Makine Öğrenmesinde

Gaussian prior, L2 regularization'a karşılık gelir. Normal dağılım varsayımı → MSE loss kullanımını gerektirir.

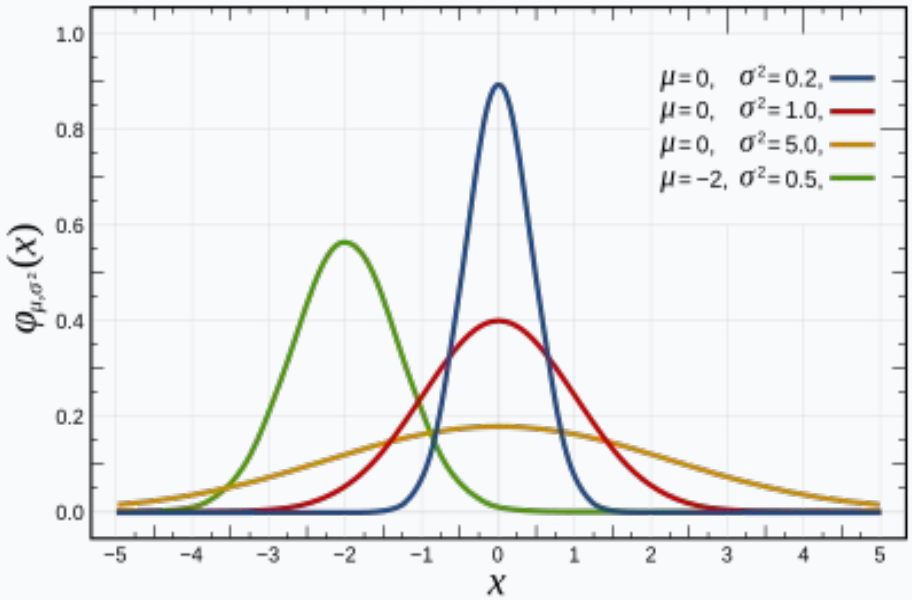

# Dağılımlar — Bernoulli Dağılımı

## Bernoulli Dağılımı

$$P(x|p) = p^x(1-p)^{1-x} \quad x \in \{0, 1\}$$

İki olası sonucu olan (0/1, başarı/başarısızlık) deneyleri modellemek için kullanılır. p parametresi başarı olasılığını temsil eder.

## Örnek: Reklam Tıklama Problemi

### Senaryo

Tıklanmasını istediğimiz reklamlar olsun.
0 = tıklanmadı, 1 = tıklandı

### Gözlemler

$x_1 = 1, x_2 = 0, x_3 = 1$
(3 gösterimden 2 tıklama)

### MLE nedir?

Bu gözlemler verildiğinde p değerini bul:
$\hat{p} = 2/3 \approx 0.667$

### Normal dağılım?

Hayır. 0/1 değerler için Normal uygun değil.
Bernoulli veya Binom kullanılmalı.

# MSE — Mean Squared Error

**Mean squared error | Hataların karelerinin ortalaması**

$$MSE = (1/n) \cdot \Sigma (y_i - \hat{y}_i)^2$$

### 📐 Negatif veri için uygundur

Kareye alma işlemi negatif hataları pozitife çevirir. Böylece pozitif ve negatif hatalar birbirini götürmez; doğru toplam ölçümü sağlanır.

### ⚡ Büyük hatalar daha fazla etki eder

Hata büyüdükçe kare işlemi cezayı katlar. 10 birim hata, 1 birim hatadan 100 kat değil $10^2 / 1^2 = 100x$ daha fazla katkı yapar. Büyük sapmaları cezalandırmak istediğinizde idealdir.

### 📏 Kullanım Alanları

Uzaklık hesabı, görüntü verisi (PSNR), enerji tüketimi tahmini, fiyat tahmini. Normal dağılım varsayımı yapılan her regresyon problemi.

### ⚠️ Dikkat: Aykırı Değerler

Outlier varsa MSE çok büyük ceza verir. Tek bir aykırı veri modeli bozabilir. Aykırı değer içeren veri setlerinde MAE daha sağlamdır.

# MAE — Mean Absolute Error

**Mean absolute error | Hataların mutlak değer ortalaması**

$$MAE = (1/n) \cdot \Sigma \, |y_i - \hat{y}_i|$$

### ⚖️ Tüm hatalar eşit ağırlıkta

Mutlak değer aldığı için büyük ve küçük hatalar aynı oranda katkı sağlar. Aykırı değerler modeli MSE kadar etkilemez.

### 📖 Yorumlaması kolay

MAE değeri hedef değişkenle aynı birimde çıkar. "Ortalama 5 TL hata yapıyorum" demek MSE'nin karekökünden çok daha sezgiseldir.

### 📏 Kullanım Alanları

Teslimat süresi tahmini, finans tahminleri, aykırı değer içeren veri setleri. Robust model istendiğinde tercih edilir.

### ⚠️ Dikkat: Gradyan Süreksizliği

Sıfırda türevsizdir: |x| fonksiyonu x=0'da kırılır. Bu gradyan hesabını zorlaştırır. Huber loss bu sorunu gidermek için tasarlanmıştır.

# MSE vs MAE — Ne Zaman Hangisi?

*İkisi de hata ölçer — fakat aykırı değerlere (outlier) farklı tepki verirler.*

| | MSE | MAE |
|---|---|---|
| **Formül** | $\Sigma(\text{gerçek} - \text{tahmin})^2 / n$ | $\Sigma\lvert\text{gerçek} - \text{tahmin}\rvert / n$ |
| **Aykırı Değer** | Büyük hataları kareler → çok cezalandırır | Tüm hataları eşit ağırlıkta cezalandırır |
| **Türevlenebilirlik** | Her noktada türevli → temiz gradyan | Sıfırda türevsiz → gradyan hesabı zor |
| **Birim** | Hedef değişkenin karesi (yorumu zor) | Hedef değişkenle aynı birim (kolay yorum) |
| **Ne Zaman** | Büyük hataları toleranssız istiyorsanız | Aykırı değer çoksa / robust model istiyorsanız |

📌 *MSE örnek: Enerji tüketimi tahmini — büyük sapmalar çok maliyetli, cezalandırılmalı.*

📌 *MAE örnek: Teslimat süresi tahmini — aykırı değer yaygın, robust model gerekli.*

# Cross Entropy

**İki olasılık dağılımının arasındaki farkı hesaplar**

$$H(p,q) = -\Sigma\, p(i) \cdot \log q(i)$$

## Tanım & Entropy

Entropy: bir dağılımdaki belirsizlik/bilgi miktarı.
Cross entropy: p (gerçek) ve q (tahmin) dağılımları ne kadar benzer?
Külback-Leibler (KL) ıraksamasına benzer, sınıflandırmada loss olarak kullanılır.

## Neden Logaritma?

Model "kedi" için %1 verirse: −log(0.01) = 4.6 (büyük ceza)
Model "kedi" için %99 verirse: −log(0.99) = 0.01 (küçük ceza)
→ Emin yanlış cevap dramatik biçimde cezalandırılır.

## Neden Softmax?

Sinir ağı son katmanı ham skorlar (logits) üretir: [2.1, 0.5, −1.2]
Softmax → olasılığa çevirir: [0.78, 0.18, 0.04] (toplam = 1.0)
Cross entropy geçerli olasılık dağılımı gerektirir → ikisi birlikte kullanılır.

## 📷 Görüntü Sınıflandırma

Kedi: tahmin=0.70, gerçek=1
→ loss = −log(0.70) = 0.36
Köpek: tahmin=0.20, gerçek=0
Kuş: tahmin=0.10, gerçek=0
→ katkıları yok

## 💡 Kural

Sınıflandırma → Cross Entropy
Regresyon → MSE veya MAE

## Neden MSE değil?

MSE + Softmax → gradyan vanishing problemi.
Cross Entropy + Softmax → çok temiz gradyan:
$\partial L/\partial \text{logit} = \text{tahmin} - \text{gerçek}$
Bu nedenle sınıflandırmada her zaman Cross Entropy tercih edilir.

# Cross Entropy — Sezgisel Açıklama

*"İki olasılık dağılımı arasındaki uzaklık" — sınıflandırma modellerinin temel kayıp fonksiyonu.*

### 🔢 Neden Logaritma?

Model 'kedi' için %1 verdiyse: loss = −log(0.01) = 4.6
Model %99 verdiyse: loss = −log(0.99) = 0.01
→ Emin yanlış cevap çok büyük ceza alır.
→ Logaritma küçük olasılıkları cezalandırmayı dramatik biçimde artırır.
→ Olasılıkların çarpımını toplamaya dönüştürür (sayısal kararlılık).

### 📊 Neden Softmax?

Ham skorlar (logits): [2.1, 0.5, −1.2]
Softmax → [0.78, 0.18, 0.04], toplam=1.0
→ Cross entropy geçerli olasılık dağılımı gerektirir.
→ Softmax + CE türevi çok basittir: ∂L/∂logit = tahmin − gerçek
→ Bu kombinasyon eğitimi hızlandırır.

### 📷 Gerçek Dünya: Kedi / Köpek / Kuş Sınıflandırması

| Kedi 🐱 | Köpek 🐶 | Kuş 🦚 |
|---|---|---|
| Tahmin: 0.70 | Tahmin: 0.20 | Tahmin: 0.10 |
| Gerçek: 1 | Gerçek: 0 | Gerçek: 0 |
| *−log(0.70) = 0.36* | *katkısı yok (0·log…)* | *katkısı yok (0·log…)* |

⚖️ *Neden MSE değil? MSE + Softmax → gradyan vanishing. Cross Entropy + Softmax → ∂L/∂logit = tahmin − gerçek → çok temiz gradyan, hızlı yakınsama.*