Örüntü Tanıma

Emir Öztürk
Oğuz Kırat

Giriş

- Sınıflandırma
- Kümeleme
- Sınıflandırma – Kümeleme
- Sınıflandırma Algoritmaları
  - Karar ağaçları
  - K-NN
  - SVM

Sınıflandırma

- Girdi verisine özelliklere göre etiket atama
- Öğrenme sırasında etiketli veri verilir
- Eğitim aşamasında model veri ile etiketler arasındaki ilişkiyi öğrenir
- Duygu analizi
- Paket analizi
- Medikal analiz

Kümeleme

- Etiketsiz veriler ile çalışılır
- Verilerin tespitinden çok gruplandırılması gerçekleştirilir
- Denetimsiz öğrenmedir
- Müşteri gruplama
- Anomali tespiti
- Veri yönlendirme

Sınıflandırma - Kümeleme

- Sınıflandırmada model hedef sınıfları bilir
- Kümelemede yakın olan küme tespiti yapılır
- Kümeleme sınıflandırmanın ön aşaması olarak kullanılabilir
  - Sonradan etiketleme için avantaj sağlar
  - Semisupervised learning
- Sınıflandırmadaki gibi doğru – yanlış ölçümü bulunmaz

Sınıflandırma algoritmaları

- Karar ağaçları
- KNN
- SVM

Karar Ağaçları

- Eldeki veriye göre bir koşul ağacı çıkartılır.
- Verinin belirli değerlerine göre yönlendirme yapılır.

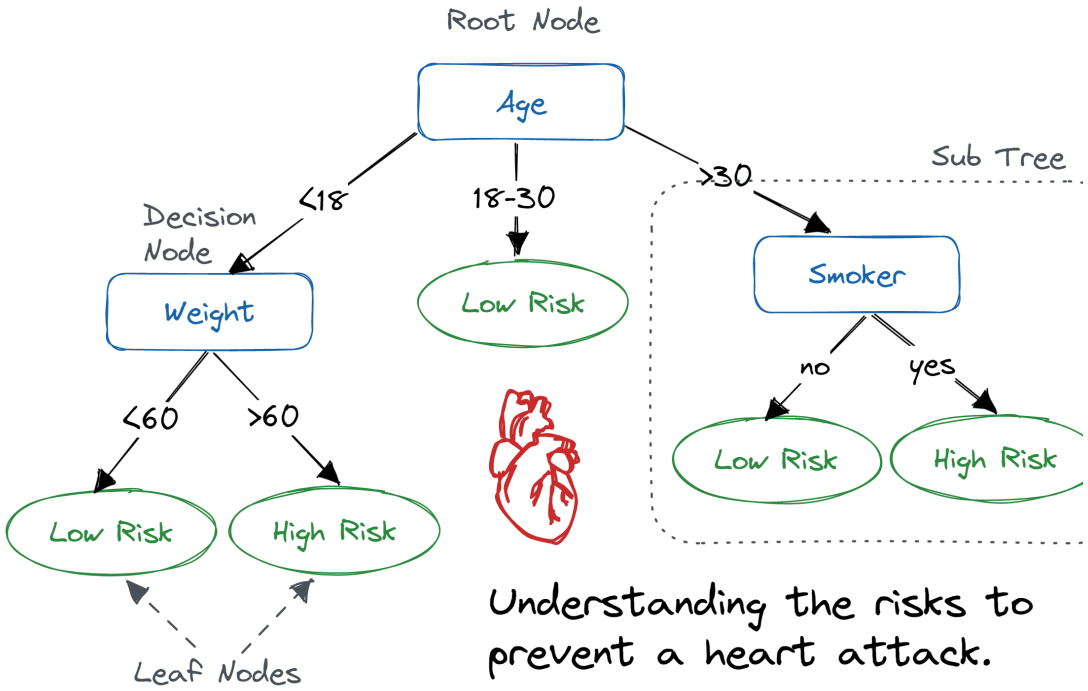

Karar Ağaçları

- ID3
- C4.5
- CART
- Random Forest

ID3

- Ross Quinlan
- Yalnızca kategorik verilerde çalışır
- Entropi (ya da bilgi kazanımı) hesabı yapılır
- En düşük entropiye sahip değer karar düğümü olarak seçilir

ID3

#	Outlook	Humidity	Wind	Play?
1	Sunny	High	Weak	No
2	Sunny	High	Strong	No
3	Overcast	High	Weak	Yes
4	Rain	High	Weak	Yes
5	Rain	Normal	Weak	Yes
6	Rain	Normal	Strong	No
7	Overcast	Normal	Strong	Yes
8	Sunny	High	Weak	No
9	Sunny	Normal	Weak	Yes
10	Rain	Normal	Weak	Yes
11	Sunny	Normal	Strong	Yes
12	Overcast	High	Strong	Yes
13	Overcast	Normal	Weak	Yes
14	Rain	High	Strong	No

ID3 - Sunny

#	Humidity	Wind	Play?
1	High	Weak	No
2	High	Strong	No
8	High	Weak	No
9	Normal	Weak	Yes
11	Normal	Strong	Yes

ID3 - Rain

#	Humidity	Wind	Play?
4	High	Weak	Yes
5	Normal	Weak	Yes
6	Normal	Strong	No
10	Normal	Weak	Yes
14	High	Strong	No

ID3

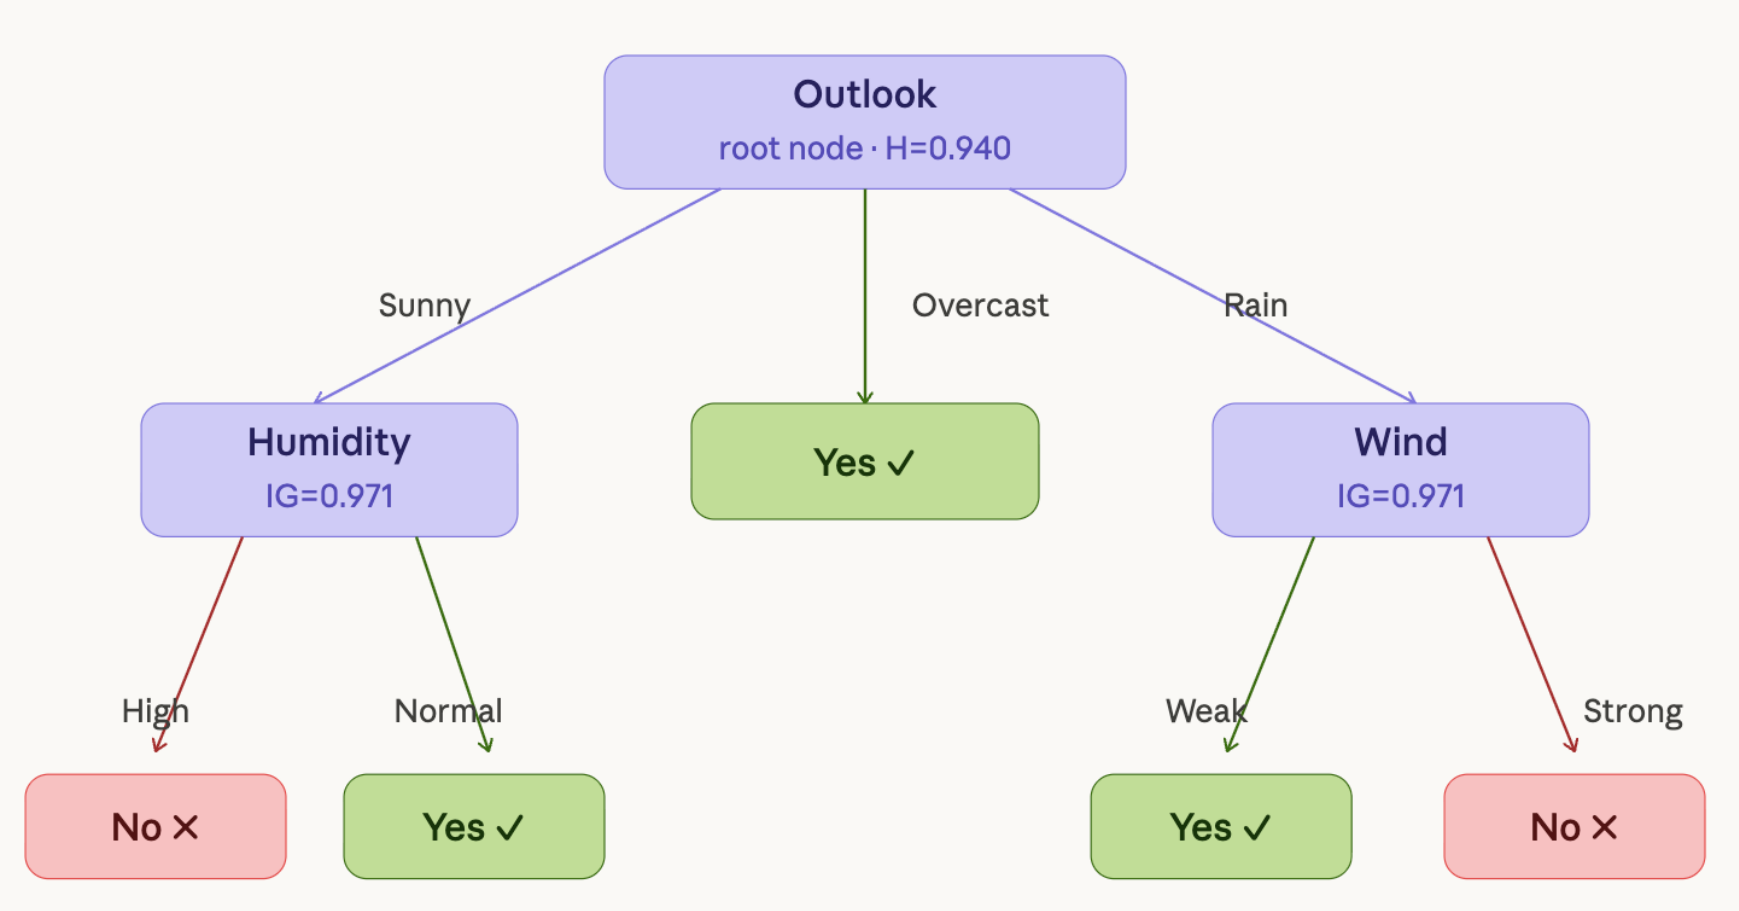
Outlook
root node · H=0.940
Sunny
Overcast
Rain
Humidity
IG=0.971
Yes ✓
Wind
IG=0.971
High
Normal
Weak
Strong
No ✕
Yes ✓
Yes ✓
No ✕

C4.5

- Ross Quinlan
- Entropi hesabı yerine kazanımın oranı hesaplanır
- Bias olmasının engellenmesi amacı ile bu işlem seçilmiştir
- Sürekli verilerde verileri belirli noktalardan bölerek çalışabilir
- Olmayan değerleri olasılık dağılımları ile tespit eder
- Ağaç küçültme (pruning) ile overfit engellenir

CART

- Breiman
- Classification and regression trees
- Düğümlerin bölünmesi için “Gini impurity” hesaplanır
- Tüm bölme ihtimalleri denenir. “Impurity” değerinin minimum olduğu bölünme seçilir
- Seçilen bir değerin yanlış sınıflandırılma değeridir

Random Forest

- Birden fazla karar ağacının karar vermesi
- Eğitim verisetinin farklı parçaları ile farklı ağaçlar oluşturulur
- Test verisinde her ağaçtan gelen sonuç ortalaması alınır

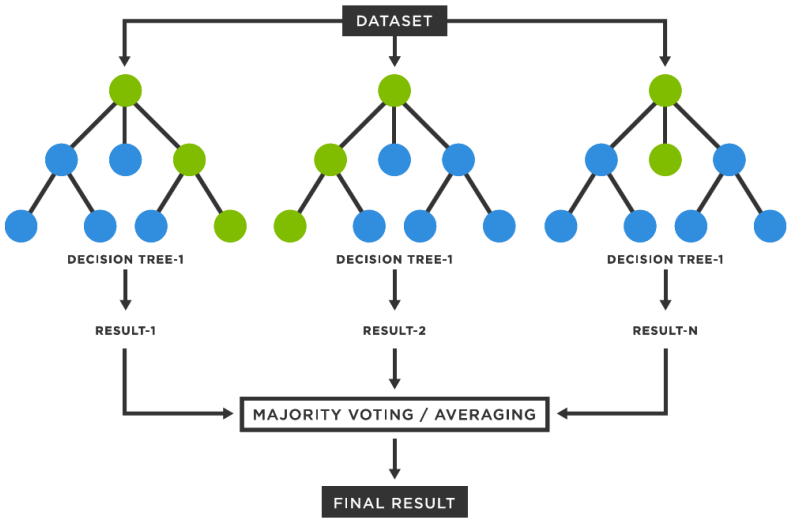

K-NN

- Lazy learner
  - Verisetinden öğrenilmiş bir model bulunmaz
  - Her istekte veriseti üzerinden yeniden hesaplama gerçekleştirilir
- Bir veri noktasının sınıflandırılması için basitçe k adet en benzer örneğe bakılır
- Benzerlik bir “uzaklık metriği” ile ölçülür
  - Öklit uzaklığı
  - Manhattan uzaklığı
  - Kosinüs benzerliği

K-NN

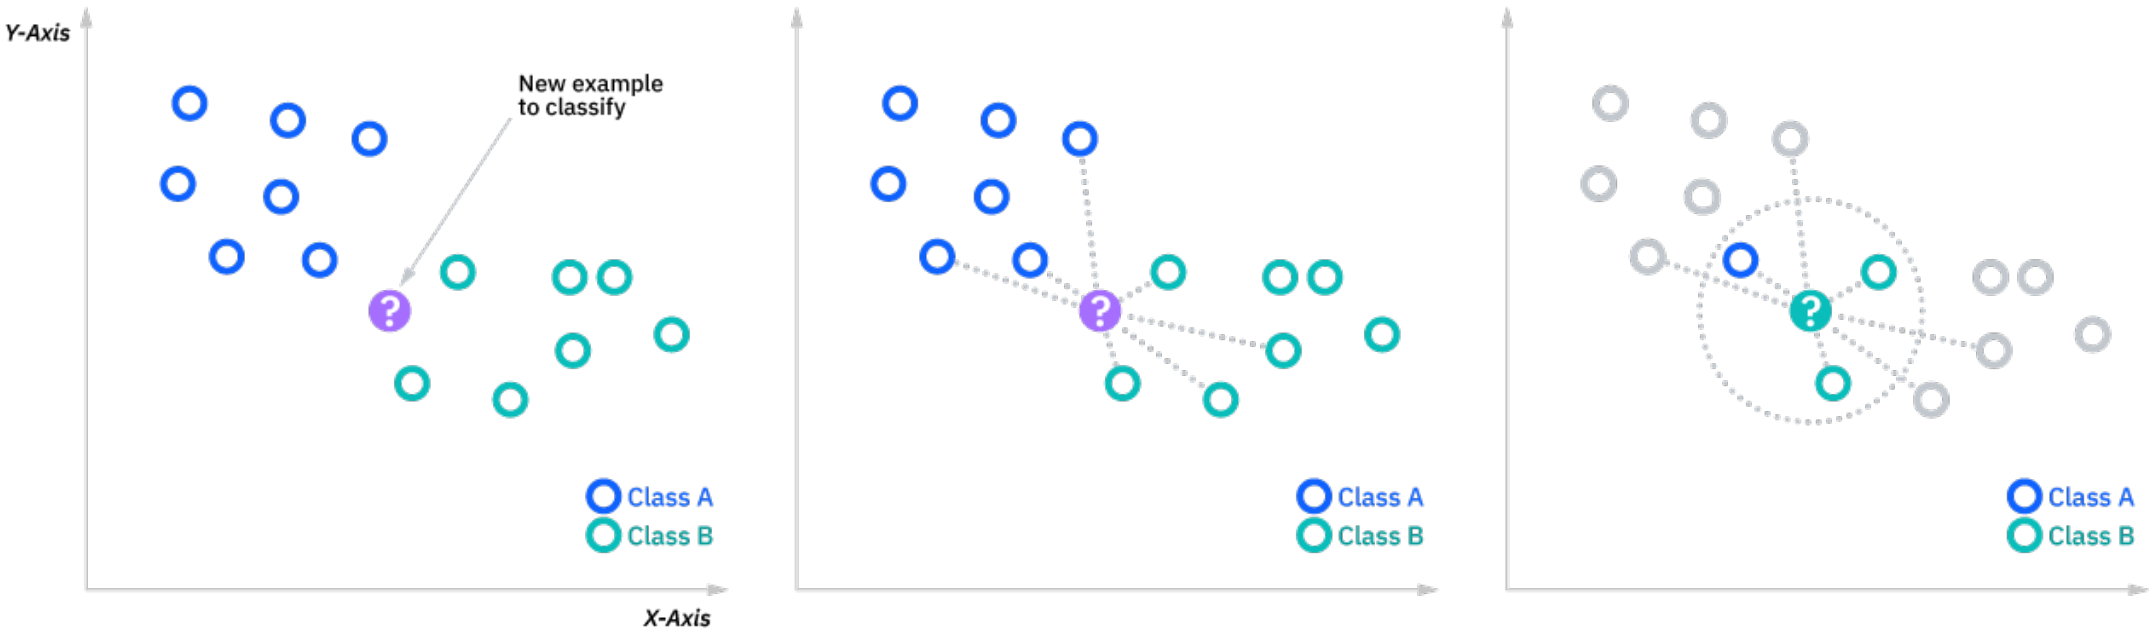
Y-Axis
New example
to classify
Class A
Class B
X-Axis
Class A
Class B
Class A
Class B

SVM

- N boyutlu bir uzayda optimum hyperplane’i bulmayı amaçlar
- Bu hyperplane oluşturulduğunda buna en yakın noktalar support vector olarak adlandırılır.
- Support vector’ler margin hesaplamada kullanılır.
- Margin’in maksimize edilmesi başarımı arttırmak için amaçlanır
- Verilerin üst boyutlara çıkarılabilmesi için kernel’lar kullanılır