




Derin Öğrenmede Model Değerlendirme Metrikleri



Neden Değerlendirme Metrikleri Önemli?

Model Karşılaştırması

Farklı model mimarilerinin performansını objektif olarak kıyaslamak için ortak bir ölçüt gereklidir.

Gerçek Dünya Etkisi

Bir tıbbi teşhis modelinde %99 accuracy yanıltıcı olabilir; asıl önemli olan nadir hastalığı kaçırmamaktır.

İş Kararları

Hangi modelin üretime alınacağına karar verirken metrikler somut kanıt sağlar.



Confusion Matrix (Doğruluk Tablosu)

		Tahmin: Pozitif	Tahmin: Negatif
Gerçek:	Pozitif	TP (True Positive) Doğru Pozitif	FN (False Negative) Yanlış Negatif
Gerçek:	Negatif	FP (False Positive) Yanlış Pozitif	TN (True Negative) Doğru Negatif

TP

Model pozitif dedi,
gerçekten pozitif

TN

Model negatif dedi,
gerçekten negatif

FP

Model pozitif dedi
ama aslında negatif

FN

Model negatif dedi
ama aslında pozitif

Doğruluk tablosu, sınıflandırma modellerinin performansını anlamanın temel yapı taşıdır.

Temel Sınıflandırma Metrikleri



Accuracy (Doğruluk)

$$(TP + TN) / \text{Toplam}$$

Tüm tahminler içinde doğru olanların oranı. Dengesiz veri setlerinde yanıltıcı olabilir.



Precision (Kesinlik)

$$TP / (TP + FP)$$

Pozitif tahminlerin ne kadarı gerçekten pozitif? Spam filtreleme gibi FP'nin maliyetli olduğu durumlarda kritik.



Recall (Sensitivity) (Duyarlılık)

$$TP / (TP + FN)$$

Gerçek pozitiflerin ne kadarı yakalandı? Hastalık teşhisi gibi FN'nin maliyetli olduğu durumlarda kritik.



F1-Score

$$F1 = 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$


Ne Zaman Kullanılır?

Precision ve Recall arasında denge kurulması gerektiğinde F1-Score tercih edilir.

Dengesiz veri setlerinde Accuracy yerine F1 tercih edilmelidir.

Özellikle sağlık, dolandırıcılık tespiti ve anomali algılama gibi alanlarda kritik öneme sahiptir.

Senaryo Karşılaştırması



ROC Eğrisi ve AUC

ROC (Receiver Operating Characteristic)

Farklı eşik değerlerinde modelin doğru pozitif oranı ile yanlış pozitif oranı arasındaki ilişkiyi gösteren eğridir.

Yatay Eksen → FPR: Negatif örneklerin yanlışlıkla pozitif olarak tahmin edilme oranı

Dikey Eksen → TPR: Pozitif örneklerin doğru şekilde yakalanma oranı (Recall)

AUC (Area Under Curve – Eğri Altındaki Alan)


AUC = 1.0 Mükemmel model

AUC = 0.9 - 1.0 Çok iyi

AUC = 0.7 - 0.9 İyi

AUC = 0.5 - 0.7 Zayıf

AUC = 0.5 Rastgele tahmin





Örnek: Sınıflandırma Metrik Hesaplaması

Senaryo: Bir e-posta spam filtresi 100 e-postayı değerlendiriyor.

Model Çıktısı (10 Örnek)

#	Gerçek	Tahmin	Sonuç
1	Spam	Spam	TP ✓
2	Normal	Normal	TN ✓
3	Spam	Normal	FN ✗
4	Normal	Spam	FP ✗
5	Spam	Spam	TP ✓
6	Normal	Normal	TN ✓
7	Spam	Spam	TP ✓
8	Normal	Normal	TN ✓

... toplam 100 e-posta değerlendirildi.

Doğruluk Tablosu

	Tahmin: Spam	Tahmin: Normal
Gerçek: Spam	TP = 35	FN = 5
Gerçek: Normal	FP = 8	TN = 52

Hesaplanan Metrikler

Accuracy

(35+52) / 100

= 0.87

Precision

35 / (35+8)

= 0.81

Recall

35 / (35+5)

= 0.875



Recall (0.875) > Precision (0.81): Model, spam yakalamada iyi ama bazı normal e-postaları da spam olarak işaretliyor (8 FP). Spam filtresinde Precision'ı artırmak kullanıcı deneyimini iyileştirir.



Regresyon Metrikleri

MSE

Mean Squared Error

$$\sum (y_i - \hat{y}_i)^2 / n$$

Hata karelerinin ortalaması. Büyük hatalara daha fazla ceza verir.

RMSE

Root Mean Squared Error

$$\sqrt{\text{MSE}}$$

MSE'nin karekökü. Orijinal birimle aynı ölçekte sonuç verir.

MAE

Mean Absolute Error

$$\sum |y_i - \hat{y}_i| / n$$

Mutlak hataların ortalaması. Outlier'lara MSE kadar duyarlı değildir.

Formüllerde Kullanılan Notasyon

y_i = Gerçek değer

$\hat{y}_i$ = Tahmin değeri

$\bar{y}$ = Gerçek değer ortalaması

n = Veri sayısı



MAPE — Mean Absolute Percentage Error

$$\text{MAPE} = \frac{1}{n} \times \sum \frac{|y_i - \hat{y}_i|}{y_i} \times 100$$

y_i = Gerçek değer $\hat{y}_i$ = Tahmin değeri n = Veri sayısı

Yorumlama

Yüzdelik hata vererek farklı ölçekteki verilerin karşılaştırılmasına olanak sağlar.

Gerçek değer sıfıra yakınsa tanımsız/aşırı büyük değerler üretir — bu durumda SMAPE veya MAE tercih edilmelidir.

MAPE Aralığı	Kalite
< %10	Çok İyi
%10 – %20	İyi
%20 – %50	Kabul Edilebilir
> %50	Zayıf



R^2 — Determinasyon Katsayısı

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

$SS_{\text{res}} = \sum (y_i - \hat{y}_i)^2$
(Kalan hata kareler toplamı)

$SS_{\text{tot}} = \sum (y_i - \bar{y})^2$
(Toplam kareler toplamı)

y_i = Gerçek değer $\hat{y}_i$ = Tahmin değeri $\bar{y}$ = Gerçek değer ortalaması

$R^2 = 1.0$

Mükemmel

Model, verinin tüm varyansını açıklıyor. Tahminler gerçek değerlerle birebir örtüşüyor.

$R^2 = 0.0$

Ortalama Düzey

Model, basit ortalamayla aynı başarıyı gösteriyor. Hiçbir ek açıklama gücü yok.

$R^2 < 0$

Yetersiz

Model, ortalamadan bile kötü. Veri yapısını öğrenememiş; modelde ciddi bir sorun var.



Örnek: Regresyon Metrik Hesaplaması

Senaryo: Bir model 6 evin fiyatını (bin ₺) tahmin ediyor.

Ev	Y_i (Gerçek)	$\hat{Y}_i$ (Tahmin)	$Y_i - \hat{Y}_i$ (Hata)	Hata	(Hata) ²	Hata/ Y_i
1	200	220	-20	20	400	0.100
2	350	310	+40	40	1600	0.114
3	150	180	-30	30	900	0.200
4	450	470	-20	20	400	0.044
5	300	280	+20	20	400	0.067
6	500	520	-20	20	400	0.040
$\Sigma / \bar{y}$	$\bar{y}=325$			$\Sigma=150$	$\Sigma=4100$	$\Sigma=0.565$

Hesaplanan Metrikler

MAE

150 / 6

25.0

bin ₺

MSE

4100 / 6

683.3

(bin ₺)²

RMSE

$\sqrt{683.3}$

26.1

bin ₺

MAPE

$(0.565/6) \times 100$

%9.4

R²

1 - 4100/93750

0.956

$R^2 = 0.956 \rightarrow$ Model fiyat varyansının %95.6'sını açıklıyor. $MAPE = \%9.4 \rightarrow$ Ortalama %9.4 sapma var, bu çok iyi seviyede. $MAE = 25$ bin ₺ $\rightarrow$ Tahminler ortalamada 25 bin ₺ sapıyor.



Tahmin (Forecasting) Metrikleri

MAPE

$$(1/n) \sum |(y_i - \hat{y}_i)/y_i| \times 100$$

Yüzdelik hata. Sıfır veya sıfıra yakın gerçek değerlerde tanımsız olur.

SMAPE

$$\sum |y_i - \hat{y}_i| / \sum (|y_i| + |\hat{y}_i|) \times 100$$

Simetrik MAPE. MAPE'nin sıfır değer sorununu kısmen çözer; 0-200% aralığında değer alır.

MAE

$$(1/n) \sum |y_i - \hat{y}_i|$$

Tahmin hatalarının mutlak ortalaması. Yorumlaması kolaydır ve aynı birimle ifade edilir.

RMSE

$$\sqrt{(1/n) \sum (y_i - \hat{y}_i)^2}$$

Büyük sapmalara daha duyarlıdır. Zaman serisi tahminlerinde yaygın kullanılır.

Hangi Metrik Ne Zaman Kullanılır?

Problem Türü	Senaryo	Önerilen Metrik	Neden?
Sınıflandırma	Dengeli veri seti	Accuracy	Sınıflar dengeli olduğunda doğru ölçüm verir
Sınıflandırma	Dengesiz veri seti	F1-Score / AUC	Azınlık sınıfın performansını ölçer
Sınıflandırma	FP maliyetli (spam)	Precision	Yanlış alarmları minimize eder
Sınıflandırma	FN maliyetli (tıp)	Recall	Kaçırılan vakaları minimize eder
Sınıflandırma	FP + FN maliyetli	F1	İki metriği de optimize eder.
Regresyon	Genel performans	RMSE / R ²	Anlaşılır ve standart ölçümler
Regresyon	Outlier dayanıklılığı	MAE	Outlier'lara daha dayanıklıdır
Regresyon	Büyük hatalar önemli	RMSE, MSE	Outliner'lar önemlidir.
Tahmin	Farklı ölçekler	MAPE / SMAPE	Yüzdelik hata, ölçek bağımsız

NOT: Pratikte birden fazla metrik gözetilerek karar verilmelidir.



Gerçek Dünya Örnekleri



Tıbbi Teşhis — Kanser Taraması

Recall

Kanserli bir hastayı "sağlıklı" olarak etiketlemek (FN) hayati tehlike yaratır. Recall yüksek tutularak kaçırılan vaka sayısı minimize edilir.



E-posta Spam Filtresi

Precision

Önemli bir e-postanın spam olarak işaretlenmesi (FP) kullanıcıyı kritik bilgiden mahrum bırakır. Precision ile yanlış alarm oranı düşürülür.



Ev Fiyat Tahmini

MAE / R^2

Birkaç aşırı lüks konut (outlier) olabilir. MAE bu uç değerlere MSE kadar duyarlı değildir. R^2 ise modelin fiyat varyansını ne kadar açıkladığını gösterir.



Perakende Satış Tahmini

MAPE

Farklı ürün kategorileri çok farklı fiyat ölçeklerine sahiptir. MAPE yüzdelik hata vererek farklı ölçeklerin karşılaştırılmasına olanak tanır.



Üretim Hattı Kalite Kontrolü

F1-Score

Hem hatalı ürünü geçirme (FN) hem de sağlam ürünü hurdaya ayırma (FP) maliyetlidir. F1-Score her iki hata türünü dengeler.