

Örüntü Tanıma

Doç. Dr. Emir ÖZTÜRK

Arş. Gör. Oğuz KIRAT

Makine Öğrenmesi İş Akışı

- **Problemi tanımla:** sınıflandırma mı, regresyon mu, anomali tespiti mi?
- **Veriyi oku:** CSV, Excel, klasör, API veya hazır veri seti.
- **Hedef değişkeni belirle:** Bir sütun veya sınıf etiketi?
- **Keşifsel veri analizi yap:** eksik değer, dağılım, sınıf dengesi, aykırı değer.
- **Veriyi böl:** Veriyi eğitim/validasyon/test olarak ayır.
- **Ön işleme uygula:** eksik değer doldurma, ölçekleme, kategorik değişken kodlama, görüntü boyutlandırma.

Makine Öğrenmesi İş Akışı

- **Temel (Baseline) model kur:** en basit makul modelle başlangıç skoru elde et.
- **Farklı modelleri dene:** Daha güçlü modelleri dene ve aynı metriklerle karşılaştır.
- **Metrikleri Yorumla:** Test verisiyle test edildiğinde aşırı öğrenme ya da az öğrenme var mı? Literatürdeki diğer çalışmalara göre başarımlar dengeli mi?
- **Hiperparametre optimizasyonu yap:** Belirli değerleri değiştirmek performansı etkiliyor mu? Öğrenme katsayısı, zamanlama algoritması, yığın boyutu? Validasyon bölümü ile test edilebilir.
- **Hata analizi yap:** Model nerelerde yanılıyor? Farklı verisetlerinde benzer performans gösterebilir mi?
- **Yayınla:** Son modeli kaydet, raporla ve yeniden kullanılabilir hale getir.

Kütüphane	Ne için kullanılır?	Ne zaman seçilir?	
NumPy	Diziler, matrisler, hızlı sayısal işlemler	Veriyi modele vermeden önce sayısal forma getirmek gerektiğinde	Makine öğrenmesinin temel veri kabı çoğu zaman sayısal dizidir.
pandas	CSV/Excel okuma, tablo temizleme, gruplayarak analiz	Tabular veriyle çalışırken	Veri setini ıanlamak ve düzenlemek için kullanılır.
scikit-learn	Klasik ML modelleri, preprocessing, metrikler, cross-validation	Tabular veri, küçük/orta ölçekli problemler, hızlı deneme	Ön işleme + model + metrik akışı tek yerde kurulabilir.
TensorFlow/Keras	Sinir ağıları, görüntü/metin/tabular derin öğrenme	Kolay model tanımı ve hızlı prototip gerektiğinde	Modeli katmanlar halinde kurup fit/evaluate/predict akışıyla eğitir.
PyTorch	Esnek sinir ağı geliştirme, custom veri setleri ve araştırma	Eğitim döngüsünü daha ayrıntılı kontrol etmek istediğinizde	Dataset, DataLoader ve eğitim döngüsü mantığını açıkça gösterir.
torchvision	Görüntü veri setleri, ImageFolder, transform, hazır CNN modelleri	Görüntü sınıflandırmada PyTorch kullanırken	Klasörden görüntü okumayı ve augmentation yapmayı kolaylaştırır.
matplotlib / seaborn	Grafik ve görselleştirme	Veri dağılımı, hata analizi ve metrik grafikleri için	Modelin ne yaptığını anlamak için görsel kanıt üretir.
joblib	Model kaydetme/yükleme	Eğitilmiş scikit-learn pipeline saklanacaksa	Aynı modeli daha sonra tekrar kullanmayı sağlar.

Soru	Problem türü	Hedef değişken	Örnek model	Metrik
Bu e-posta spam mi?	Sınıflandırma	spam / değil	LogisticRegression, RandomForest, CNN	F1, precision, recall
Yarın satış kaç adet olur?	Regresyon / tahmin	sayısal satış	RandomForestRegressor, GradientBoosting, MLP	MAE, RMSE, R2
Bu sensör kaydı normal mi?	Anomali tespiti	normal / anormal veya etiketsiz	IsolationForest, OneClassSVM, autoencoder	PR-AUC, precision@k, uzman incelemesi
Bu görsel hangi sınıfa ait?	Görüntü sınıflandırma	sınıf adı	CNN, ResNet, EfficientNet, ViT	Accuracy, macro F1

ML Projeleri Tasarlamak/Sunmak

- Öncelikle yapılan iş doğru anlaşılmalıdır ve açıklanmalıdır. Amaç nedir? Bu işi neden yapıyoruz, hangi problemi çözüyoruz? Sunumlarda ve raporlarda ilk önce bu anlatılmalıdır.
- Veri seti iyi tanınmalıdır. Ne kadar veri var? Nasıl toplanmış? Varsa sınıflar, birimler neler? Veri seti kullanıma açık mı? Veri seti problemimize uygun ve yeterli mi? Bu veri setinin iyi/kötü yanları neler?
- Veri seti görselleştirilmeli, örneğin veri setinden örnek görüntüler, ya da grafikler oluşturulmalıdır. Ayrıca ortalama, ortanca, standart sapma gibi istatistikî değerler de (uygunsa) sunulabilir. Bu olası hataları da engelleyecektir.

ML Projeleri Tasarlamak/Sunmak

- Veri setinden eksik/boş/hatalı alanlar var mı?
- Gereksiz veriler var mı? Örneğin ID sütünü öğrenme için tamamen gereksiz olabilir.
- Sınıflar dengeli mi?
- Train/val/test bölünmüş mü? Bölünmediyse biz nasıl böleriz?
- One-hot encoding, veri doldurma (örneğin matematiksel interpolasyon) ya da veri silme yapmalı mıyız?
- Verileri belli bir aralığa (Örneğin 0-1) çekmek modelin eğitilmesi için fayda sağlayabilir.

ML Projeleri Tasarlamak/Sunmak

- Sorun ve veri setimize uygun model mimarileri ya da makine öğrenmesi yöntemleri neler? Bunlardan veri setimize uygun basit bir tanesini temel model olarak seçebiliriz.
- Modelimizi veri setinde eğitiriz. Bu sırada her döngüde hata fonksiyonu, başarımlar metrikleri vb. raporlamak oldukça faydalıdır.
- Bizim problemimize uygun başarımlar metrikleri nelerdir? Örneğin her sınıflandırma problemi için doğruluk en iyi metrik olmayabilir. Bu nedenle birden fazla metrik takip edilmeli, en önemli olanların iyi olması yönünde çalışma yapılmalıdır.
- Temel modeli eğittikten sonra bu alanda kullanılan diğer model mimarilerini araştırarak onlarla da benzer şekilde eğitim yapılabilir.

ML Projeleri Tasarlamak/Sunmak

- Eğitim sırasında test başarımları artmıyorsa ama sonuçlar yeterliyse erken durdurma yapılabilir. Sonuçlar yeterli değilse hipermetreler, veri ya da model mimarisi uygun olmayabilir.
- Farklı modellerin metrikleri karşılaştırılabilir. Doğruluk matrisleri okunarak modelin hatalı yerleri değerlendirilebilir.
- Tüm deneylerde deterministik ve tekrarlanabilir sonuçlar almak için rastgelelik çekirdeği aynı sayıya sabitlenmelidir. Örneğin veriler modele karışık gelmesi model öğrenmesi için sıralı gelmesinden avantajlı olabilir, ama deneyler sırasında karışık sıra hep aynı olmalıdır ki karşılaştırmayı modeller/hipermetreler üzerinden yapabilelim.

ML Projeleri Tasarlamak/Sunmak

- En uygun modeller arasında hiper-parametre optimizasyonu yapılabilir, bu işlem başarıımı arttırabilir. Model mimarisini değiştirmeden yığın boyutu, drop-out oranı, öğrenme katsayısı, öğrenme katsayısı zamanlayıcı vb. değiştirerek başarıım arttırmaya çalışılabilir.
- Modellerin büyüklükleri (parametre sayısı gibi) raporlanabilir.
- Bazen modeli sıfırdan eğitmek yerine fine-tune etmek ya da transfer learning tercih edilebilir. Fine tune ve sıfırdan eğitim arasındaki fark da karşılaştırılabilir.
- Mimaride küçük değişimlerin çalışma hızına ve model başarısına katkısı değerlendirilebilir. Örneğin CNN katman sayısını arttırma başarıımı arttırabilir. Aktivasyon fonksiyonları başarıımı etkileyebilir
- İşlem sonunda tüm süreç raporlanır. Eğitim ve testte kullanılan donanım ve yazılım sürümlerinin verilmesi önemlidir.

ML Projeleri Tasarlamak/Sunmak

- Modelin zayıf olduğu noktalar nelerdir? Metriklerimiz tutarlı mı?
- Hangi hiper-parametreler en iyisi? Denenen modeller arasında en başarılısı hangisi?
- Tablo halinde, grafiklerle ve yazı olarak mutlaka anlatılmalı.
- Aynı işe yönelik farklı verisetleri üzerinde test yapabilirsiniz.
- Farklı veri setlerini uygun şekilde birleştirebilirsiniz.
(Test kısımlarını ayrı ayrı raporlamak çok daha doğru)
- <https://scholar.google.com/> üzerinde benzer problemi çözen makalelere göz atabilirsiniz. Kullanılan veri setleri, yöntemler ve sonucu nasıl göstermişler bilgi verebilir.

Bu Ders Kapsamında Gördüğümüz Hatalar

- Ne iş yapıldığını bilmemek/anlatmadan teknik kısma girmek.
- Çok yetersiz/kalitesiz veri seti kullanmak.
- Kullanılan modellerin ne olduğunu araştırmadan, kısaca bilgi vermeden geçmek.
- Metrikleri doğru seçmemek açıklayamamak.
- Eğitim/validasyon/test ayrımı yapmamak ya da tutarlı yapmamak.
- Hiçbir karşılaştırma olmaması.
- Ön işleme işleminin eğitime farklı, teste farklı olması.
- Deneylerin tekrarlanabilir olmaması.
- Deneyebileceğimiz bir ara yüz (CLI/GUI farketmez olmaması) ya da kodda bulunamaması.
- Raporlarda siyah arkaplanlı kod kullanmak 😞

Bu Ders Kapsamında Gördüğümüz Hatalar

- Beklenen: Doğru veri seti, araştırma yapılması, doğru modeller, düzgün deneyler, sonuçları anlatmak, yorum.

Deney nedir?

Random seed sabit, aynı veri, aynı sürümler. Aynı şekilde yapıldığında aynı sonuçlar.

- Ön işleme yapma/yapmama/nasıl yapma?
- Seçilen model mimarileri
- Seçilen model mimari değişiklikleri (katman sayısı, kanal sayısı, aktivasyon fonk. vb.)
- Hiper-parametreler (dropout, loss fonksiyonu, batch size, LR, LR Scheduler)

Hepsi gerekli değil

Bunlar test metriklerini ve/veya çalışma hızını nasıl etkiliyor? Karşılaştır.