

Örüntü Tanıma

Yapay Zeka Etiğinin Temel Unsurları

- Veri
- Ön Yargı
- Şeffaflık ve Açıklanabilirlik
- Gizlilik
- Hesap Verilebilirlik
- Üretken Yapay Zeka'nın Yeni Sorunları

Veri Etiği

- **Veri kimden geliyor?**

ImageNet (2009): 14 milyon görsel, Flickr gibi kaynaklardan kullanıldı. Etiketleme: Amazon MechanicalTurk ile yapıldı. Ucuz iş gücü kullanıldı.

- Clearview AI isimli özel bir şirket 2017-2020 arası Facebook, Instagram ve LinkedIn gibi platformlardan veri topladı.

İnternette açık olan her şey kullanılabilir mi?

Veri Etiği

- Veri kimi temsil ediyor?

Büyük veriler, insanların yanlılığını yansıtıyor olabilir mi?

ImageNet içerisindeki insan kategorisinde batılı, beyaz, genç insanların çoğunlukta olması.

Yani veri seti dünyayı değil, veri toplayanın görebildiği dünyayı temsil ediyor

Veri Etiği

- Veri ne amaçla kullanılacak?

Toplanan verinin kullanıldığı amaçta kişinin **açık rızası** var mı?
Örneğin telefonunuzun kilidini açmak için kullandığınız yüz verisi sınır geçişlerinde, kredi skoru hesaplanmasında ya da suçlu aramasında kullanılabilir mi?

- Garbage In, Garbage Out

Kötü veri = kötü sonuçlar

Ön Yargı (Bias)

Veri doğru olsa bilse algoritmalar ön yargıları öğrenebilir.

Tarihsel Ön Yargı:

Amazon işe alım modelinde on yıllık başvuru verisiyle eğitilen model, erkek mühendisleri tercih etmeye başladı. Ön işlemede cinsiyeti çıkarsalar çıkarılsa bile model kelime seçimi gibi faktörleri öğrenerek erkek adayları seçmeye daha yatkındı.

Ön Yargı (Bias)

Örneklem önyargısı:

Veri belirli grupları yeterince temsil etmediğinde ya da aşırı temsil ettiğinde ortaya çıkar.

Etiketleme önyargısı:

Etiketleyen insanların kendi kültürel arka planları, varsayımları ve önyargıları veriye geçer.

Bir Çinli için saldırgan olan, bir Fransız için olmayabilir; bir Amerikalı için sorun olmayan bir paylaşım, bir Türk için sorun olabilir.

Ön Yargı (Bias)

Vekil (proxy) Ön Yargı: Amazon örneğinde olduğu gibi, ayrımcılık ya da önyargıya sebep olacak veriler veri setinden çıkarsa bile, algoritmanın diğer ipuçlarından o ayrımı yapabilmesidir.

Örneğin, ırka yönelik ayırım yapılması yasak olsa da ABD'de posta kodu verisinden kişinin yaşadığı yer ve ırkın dolaylı olarak kullanılması.

COMPAS: Bir Sınıflandırıcının Adalet Sorunu

ABD'de yargıçların kefalet ve tahliye kararlarında kullandığı bir risk skorum sistemi. Sanığın tekrar suç işleme ihtimalini tahmin ediyordu.

Siyahi sanıklar; tekrar suç işlemediği halde 'yüksek risk' olarak işaretlenme oranı beyaz sanıkların yaklaşık iki katıydı. Yani 'yanlış pozitifler' eşit dağılmıyordu.

Yanlış 'Yüksek Risk' Etiketleri

(suç işlememiş sanıklarda)

%45

Siyahi sanıklar

%23

Beyaz sanıklar

Ders: Doğruluk (accuracy) tek başına 'adil' demek değildir.

Gender Shades: Yüz Tanımada Önyargı

Joy Buolamwini & Timnit Gebru, MIT — 2018

CİNSİYET SINIFLANDIRMA HATA ORANLARI

Grup	IBM	Microsoft	Face++
Açık tenli erkek	%0.3	%0.0	%0.7
Açık tenli kadın	%7.1	%1.7	%6.0
Koyu tenli erkek	%12.0	%6.0	%0.7
Koyu tenli kadın	%34.7	%20.8	%34.5

~35x

daha kötü performans
açık tenli erkeklere kıyasla

Bu sistemler havalimanları, polis ve işe alımlarda kullanılıyordu. "Veri seti dengesizdi" — ama sonuçlar bir grup insan için açık biçimde adaletsizdi.

Şeffaflık ve Açıklanabilirlik

- Klasik makine öğrenmesi modelleri, belirli ölçüde açıklanabilirken derin öğrenme modelleri kapalı kutu olma eğilimindedirler.
- Örneğin bir kredi başvurusunun bankanın yapay zeka modeli tarafından ret edildiğini varsayalım. Banka bu durumun nedenini açıklayabiliyor mu yoksa bu “ticari bir sır” mı?
- XAI (Explainable AI) bu açığı kapatmaya çalışan bir araştırma alanıdır. Hangi özellikler sonuca en çok katkı yapıyor? Görüntünün hangi alanları sınıflandırmayı etkiliyor? gibi sorulara çözüm arar.

Gizlilik

- Modeller veriyi hatırlar. Bu nedenle modellere çeşitli saldırılar yapılabilir:

Üyelik Çıkarımı Saldırısı (Membership inference attack):

Model sonuçtan eminse, bu veri eğitim setinde olabilir. Aşırı öğrenmiş, küçük eğitim setli ve büyük modellerde risk daha yüksek.

Model Ters Çevirme (Model Inversion): Modelin kararının gradyanlarını terse çevirerek veriye erişme saldırısıdır. "Şu sınıfı maksimize eden girdi" optimizasyon problemi olarak çözülüyor (basitçe: sınıfa giren tipik girdiye yakınsıyorsunuz).

Yüz tanıma sistemine bir kişinin adının verildiğinde modelin ağırlıklarından yüze geri dönülmesi mümkün olabiliyor.

Veri Sızıntısı (Data Leakage): Özellikle büyük dil modellerinde modelin eğitim verisini kelimesi kelimesine üretebilmesidir. Özellikle GPT'nin eski sürümlerinde büyük bir problem.

Örnek: Ali Yılmaz'ın e-posta adresi ...'dir. Boşluğu tamamla.

Gizlilik

Savunma mekanizmaları:

Diferansiyel gizlilik: Gürültü ekleyerek bireysel iz silinir

Federe öğrenme: Veri cihazda kalır, sadece model güncellemesi paylaşılır

Anonimleştirme: Kişisel bilgiler silinir (Proxy bilgi sorunu)

Hesap Verilebilirlik

Sistem hata yaparsa kim sorumlu olacak?

- YZ alanında yasal boşluklar tam olarak doldurulmuş değil.

Senaryo: Otonom bir araç yayaya çarpıyor.

- Araç şoförü: Sistemi izlemeliydi, ama otonomi vaat edildi.
- Mühendislik Ekibi: Algoritmayı tasarladı ve eğitti. Test veri setinden oldukça başarılıydı.
- Üretici Firma: Ürünü pazarladı, kullanım sözleşmesine yazdı.
- Veriyi Toplayan Firma: Gerekli olması gereken uç durumlar veri setinde yoktu.

Sorumluluk çukuru (Responsibility gap): *hiç kimse tam olarak sorumlu sayılamadığında ortaya çıkan boşluk*

Sınıflandırma Pratikte Ne Anlama Geliyor?

Biyometrik tanıma

Yüzünüz şifrenizle aynı 'kimlik' işlevini görüyor — ama değiştiremezsiniz.

Tıbbi görüntüleme

Yanlış pozitif: gereksiz tedavi. Yanlış negatif: gözden kaçan hastalık. Örneğin açık ten/koyu tende farklı sonuçlar

Sosyal medya sınıflandırması

İçerik düzenleme — meşru ifade ile zararlı içerik arasındaki çizgi kimde?

Gözetim ve Parmak İzi

Bir tanıma sistemi 'herkesi her yerde' takip edebilir hale geliyor. Özel firmalar bunu kötü amaçlı kullanabiliyor.

Kredi/işe alım skorlama

Tarihsel önyargılar bir 'objektif puana' dönüşerek meşrulaşıyor.

Otonom karar sistemleri

İnsan döngüden çıkınca suçlu kim

Üretken Modeller, Yeni Sorunlar

- **Sentetik medya, deepfake:** dolandırıcılık, iftira, siyasi manüpilasyonlar.
- **Halüsinasyonlar:** İnandırıcı yanlışlık, tıp ve hukuk alanında ciddi Zarar verebilir.
- **Telif Hakkı:** Rıza alınmadan eğitim verisi toplanması, çıktının kime ait olduğu.
- **Çevre:** Büyük modellerin eğitimi ve çalışması sırasındaki enerji kullanımı ve karbondioksit salınımı

Yasal Alt Yapı

- **AB Yapay Zeka Yasası:**

- Kamusal ölçekte yüz tanıma, sosyal skorlama, bilinçaltı manipülasyon yasaklanıyor.
- İnsan kaynakları (CV taraması), kredi puanlama, eğitim (sınav puanlama), sınır kontrolü, kritik altyapı, kolluk kuvvetleri. Bu sistemler şeffaflık, uygunluk değerlendirmesi, denetim ve insan denetimi yükümlülüklerine tabi.
- Chatbotlar, görüntü üreten YZ: kullanıcıya "bu içerik yapay zekâ tarafından üretilmiştir" denmek zorunda.
- Spam filtreleri, oyun NPC'leri, basit öneri sistemleri için düzenleme yok.

AB pazarında ürün sunacak her şirket bunlara uyacak.

Kişisel Veriler Hakkında: GPDR, KVKK...

Öneriler: OECD YZ İlkeleri, UNESCO YZ Etiği Tavsiyeleri, IEEE Ethically Aligned Design. (Bağlayıcı değil)

